

FIAP

# DEEP LEARNING

• • • • . . . +  
• • • . . . . .  
• + .  
+ .

## FELIPE GUSTAVO SILVA TEODORO

### PROFESSOR

- Doutorando em Sistemas de Informação pela USP (Deep Learning).
- Mestre em Sistemas de Informação pela USP (Inteligência Computacional).
- MBA em Engenharia de Software pela FIAP.
- Tecnólogo em Análise e Desenvolvimento de Sistemas pela Faculdade de Tecnologia Termomecânica .
- Mais de 17 anos de experiência profissional em TI em desenvolvimento de sistemas, Gestão de TI, Data Science e Machine Learning.
- Autor de artigos acadêmicos e entusiasta de Inteligência Artificial.
- Head de Data Science da empresa Kogui.

 [proffelipe.teodoro@fiap.com.br](mailto:proffelipe.teodoro@fiap.com.br)

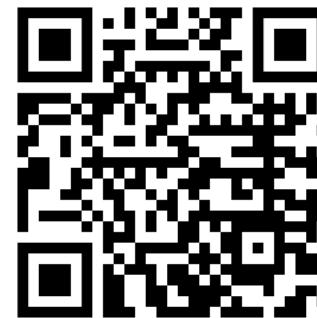
• • • • • +  
• • • • .  
• + .  
+ •

# FELIPE GUSTAVO SILVA TEODORO

## PROFESSOR

|  
+

- Péssimo jogador de CS
- Apaixonado por formação e desenvolvimento de pessoas
- Pessoa LGBTQIA+ 🏳️🌈

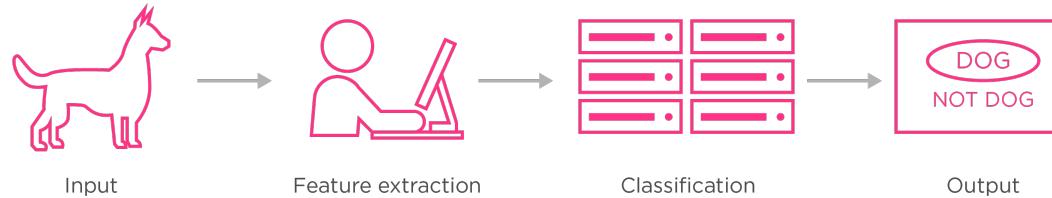


LinkedIn

✉ proffelipe.teodoro@fiap.com.br

# REDES NEURAIS ARTIFICIAIS

## TRADITIONAL MACHINE LEARNING

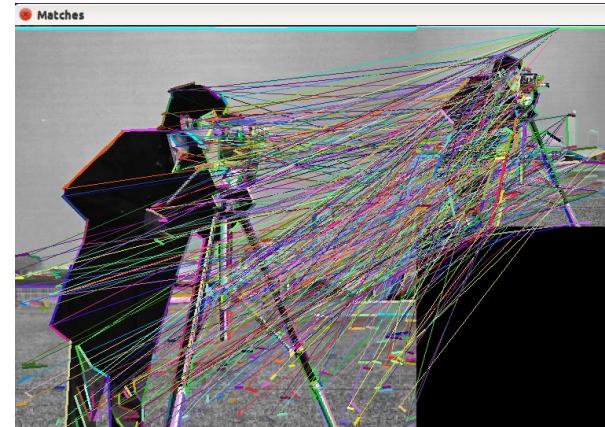
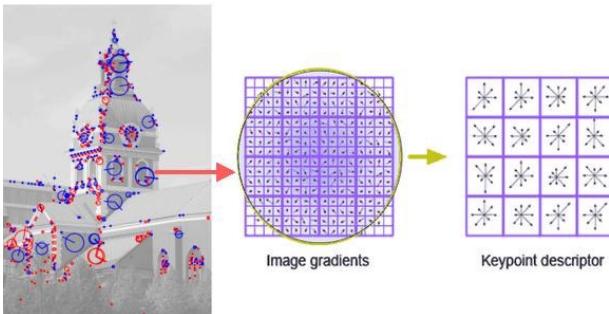


## DEEP LEARNING



## PROBLEMAS COMPLEXOS

- Técnicas de extração de características em imagens:



# PROBLEMAS COMPLEXOS

Poodle ou frango frito?



# PROBLEMAS COMPLEXOS

Cão ou rosca?



## PROBLEMAS COMPLEXOS

Chihuahua ou muffin?



@teenybiscuit

## PROBLEMAS COMPLEXOS

Frango cru ou Donald Trump?



## • • • • . PROBLEMAS COMPLEXOS

+ Nós, humanos, após milhões de anos estamos começando a perder para as máquinas...

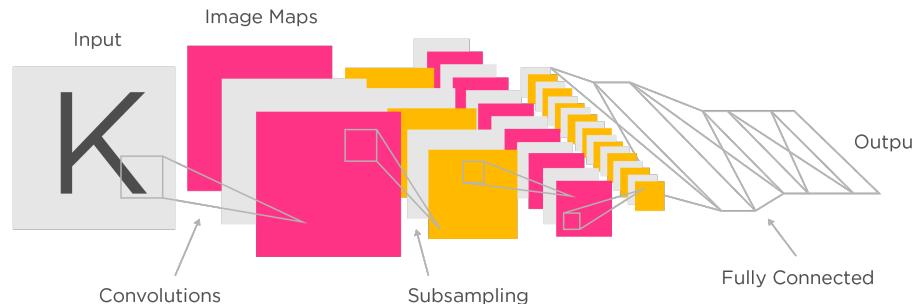


# DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS

- Arquitetura tradicional LeNet-5

## Review: LeNet-5

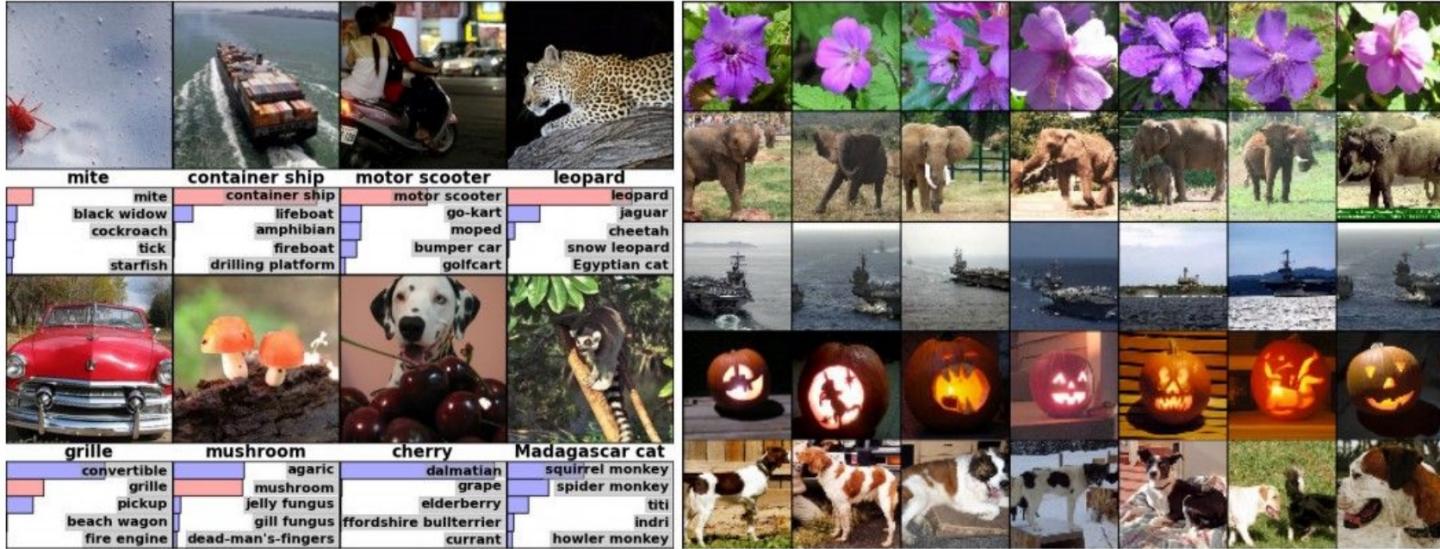
(LeCun et al., 1998)



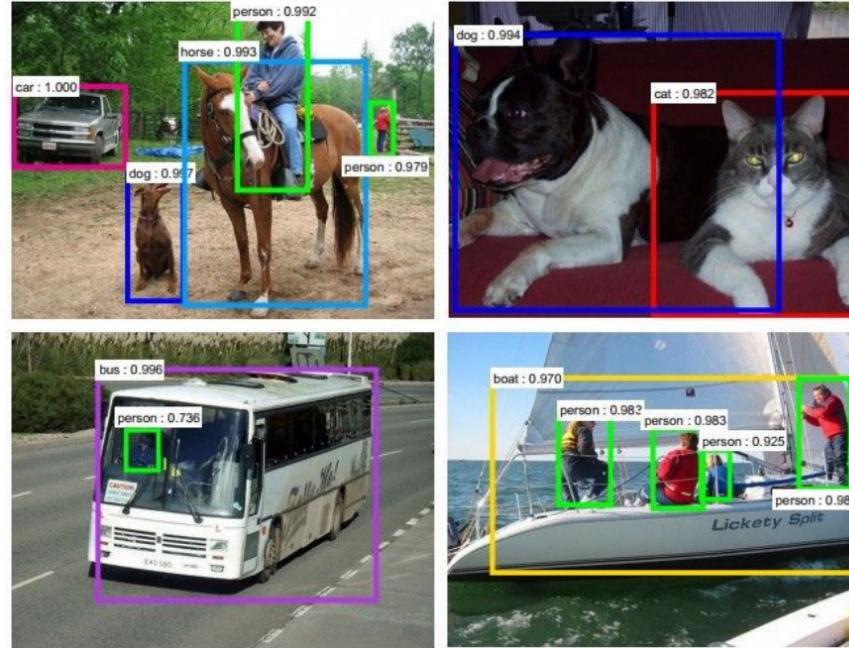
Conv filters were 5x5, applied at stride 1

Subsampling (Pooling) layers were 2x2 applied at stride 2  
i.e. architecture is [CONV-POOL-CONV-POOL-FC-FC]

# DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS



# DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS



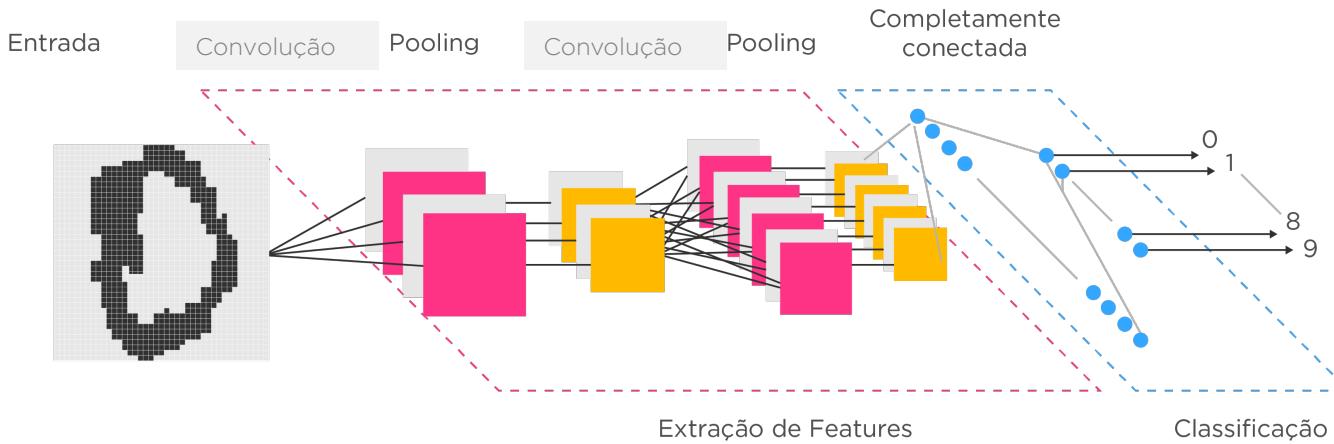
# DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS



<https://experience.huia.haus/>

# DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS

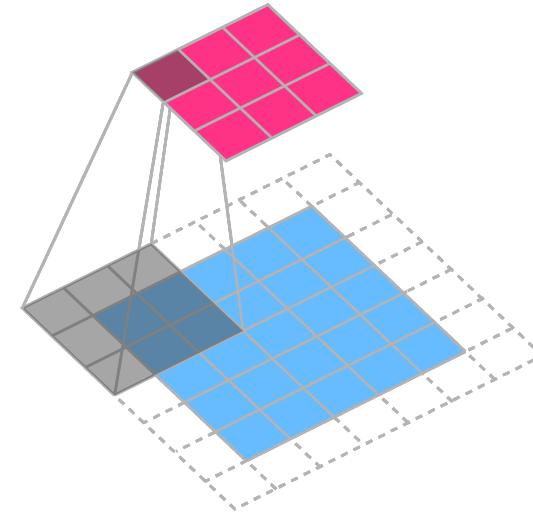
## Arquitetura Geral



Fonte: MEDEIROS NETO, F. G.; PINTO JÚNIOR, R. F.; ROCHA, M. G. O. et al. Aprendizado profundo: conceitos, técnicas e estudo de caso de análise de imagens com Java. III Escola Regional de Informática do Piauí. *Livro Anais - Artigos e Minicursos*, v. 1, n. 1, pp. 465-486, jun. 2017.

# REDES NEURAIS CONVOLUCIONAIS CONVOLUÇÃO

A ideia é que uma **convolução** (ou um detector de atributos de rede neural local) mapeia uma dada região de certa imagem para um “mapa de atributos”.



# REDES NEURAIS CONVOLUCIONAIS

## CONVOLUÇÃO

A ideia é que uma **convolução** (ou um detector de atributos de rede neural local) mapeia uma dada região de certa imagem para um “mapa de atributos”.

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

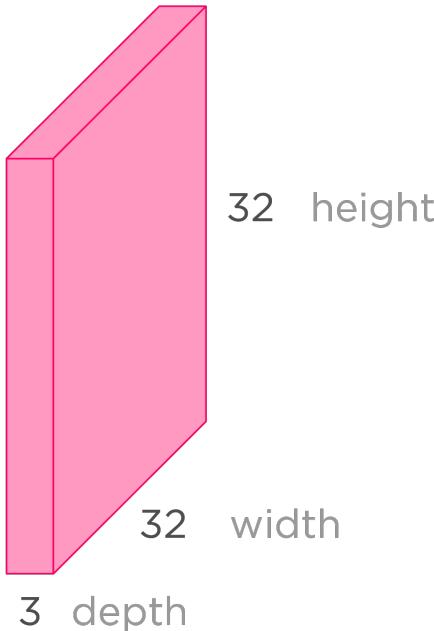
Image

4		

Convolved  
Feature

# REDES NEURAIS CONVOLUCIONAIS

## CONVOLUÇÃO

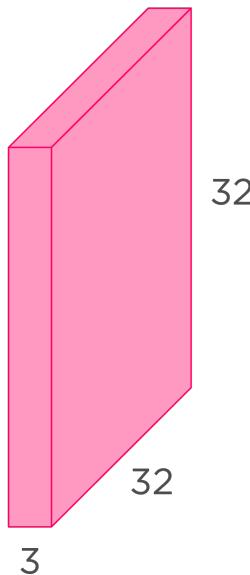


- Imagem  $32 \times 32 \times 3 \rightarrow$  mantém a estrutura espacial preservada.

# REDES NEURAIS CONVOLUCIONAIS

## CONVOLUÇÃO

32x32x3 image



5x5x3

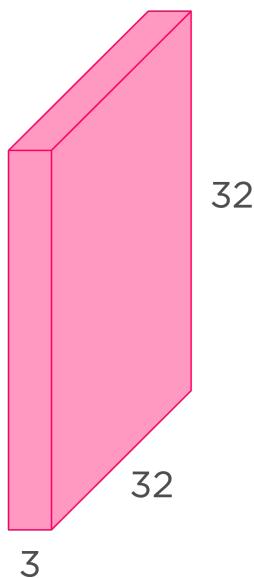


- Filtro.
- Convolve o filtro com a imagem.
- Por exemplo: “se desliza a imagem espacialmente, computando produtos escalares”.

# REDES NEURAIS CONVOLUCIONAIS

## CONVOLUÇÃO

32x32x3 image



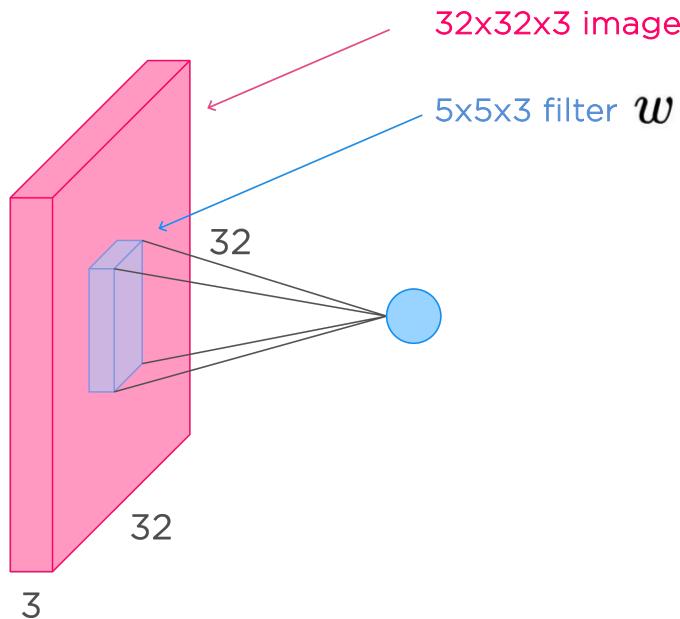
5x5x3



- Os filtros sempre estendem a profundidade total do volume de entrada.
- Convolve o filtro com a imagem. Por exemplo: “Se desliza a imagem espacialmente, computando produtos de pontos”.

# REDES NEURAIS CONVOLUCIONAIS

## CONVOLUÇÃO

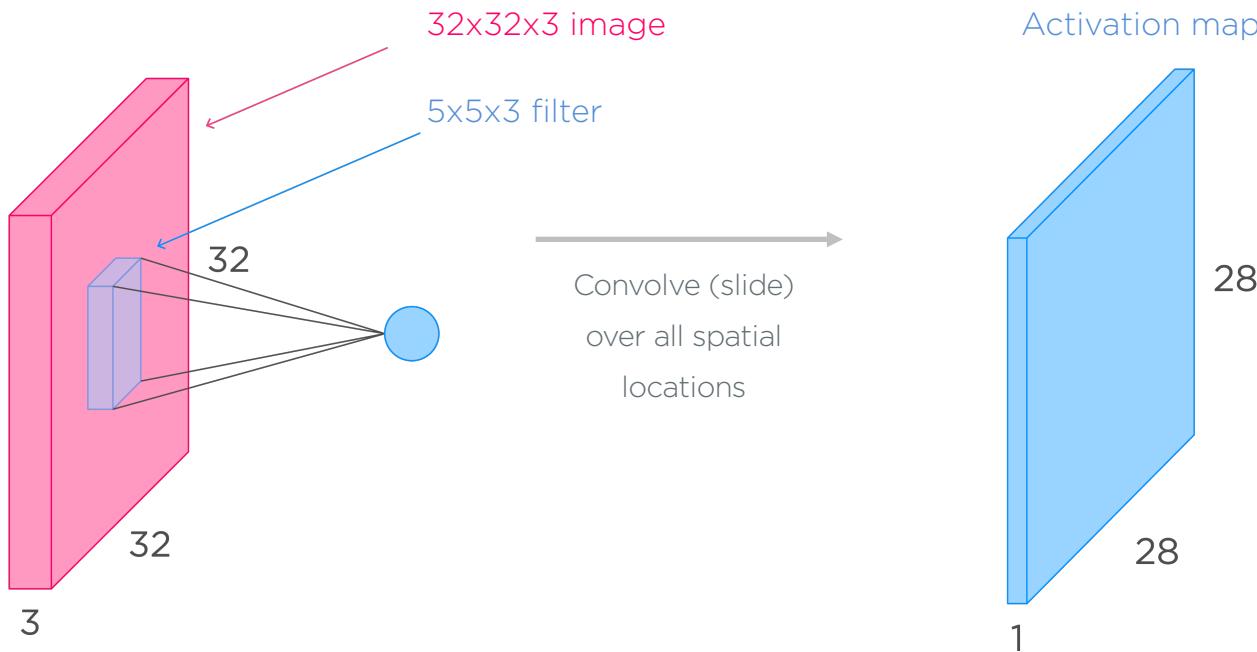


- 1 número: pedaço de  $5 \times 5 \times 3$  da imagem (ou seja,  $5 * 5 * 3 =$  produto escalar de 75 dimensões + bias).

$$w^T x + b$$

# REDES NEURAIS CONVOLUCIONAIS

## CONVO LUÇÃO



# REDES NEURAIS CONVOLUCIONAIS

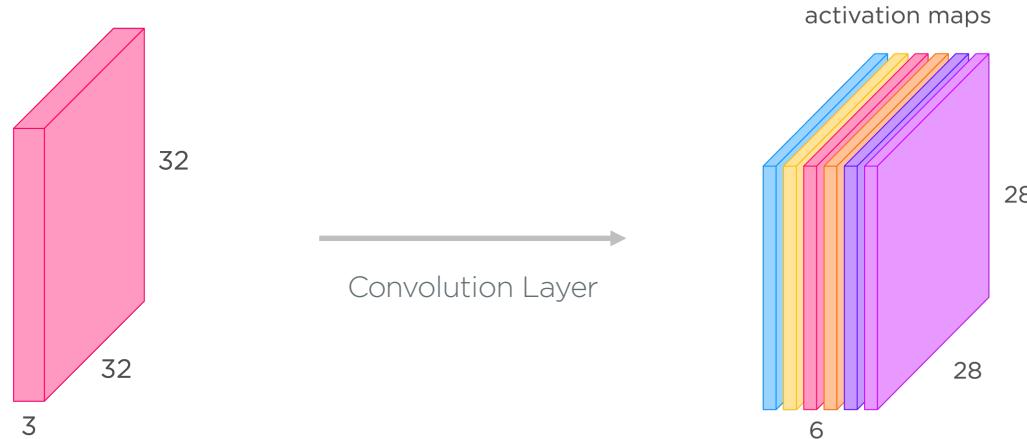
## CONVOLUÇÃO



# REDES NEURAIS CONVOLUCIONAIS

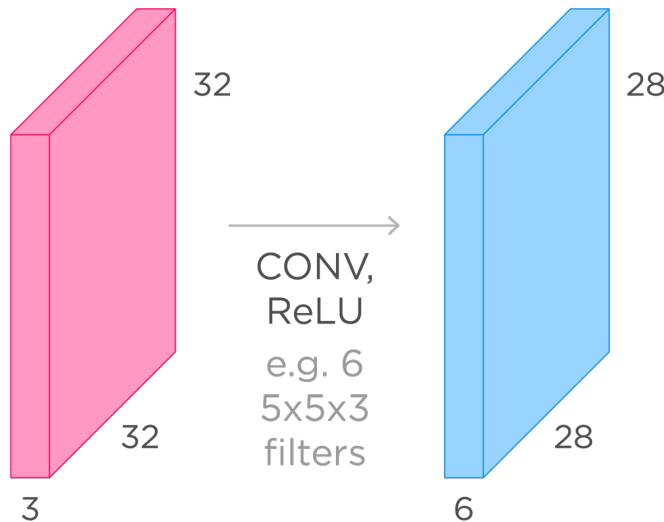
## CONVOLUÇÃO

- Por exemplo, se tivéssemos seis filtros  $5 \times 5$ , obteríamos seis mapas de ativação separados.
- Receberíamos uma “nova imagem” de tamanho  $28 \times 28 \times 6$ !



# REDES NEURAIS CONVOLUCIONAIS

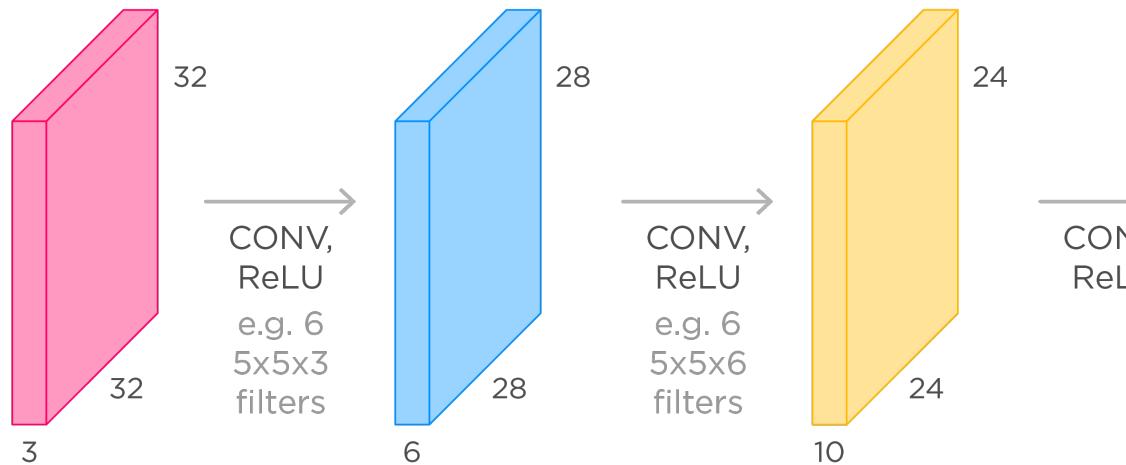
## CONVO LUÇÃO



- ConvNets, então, são uma sequência de camadas de convolução intercaladas com funções de ativação.

## REDES NEURAIS CONVOLUCIONAIS CONVOLUÇÃO

- ConvNets, então, são uma sequência de camadas de convolução intercaladas com funções de ativação.



# EXEMPLOS DE CONVOLUÇÃO

Input						
4	9	2	5	8	3	
5	6	2	4	0	3	
2	4	5	4	5	2	
5	6	5	4	7	8	
5	7	7	9	2	1	
5	8	5	3	8	4	

$n_H \times n_W = 6 \times 6$

Filter		
1	0	-1
1	0	-1
1	0	-1

\*

Result		
2		

<https://indoml.com>

**Parameters:**  
Size:  $f = 3$   
Stride:  $s = 1$   
Padding:  $p = 0$

$$\boxed{2} = 4*1 + 9*0 + 2*(-1) + 5*1 + 6*0 + 2^*(-1) + 2*1 + 4*0 + 5^*(-1)$$

Input						
4	9	2	5	8	3	
6	2	4	0	3		
2	4	5	4	5	2	
5	6	5	4	7	8	
5	7	7	9	2	1	
5	8	5	3	8	4	

$n_H \times n_W = 6 \times 6$

Filter		
1	0	-1
1	0	-1
1	0	-1

\*

Result		
2	6	

<https://indoml.com>

**Parameters:**  
Size:  $f = 3$   
Stride:  $s = 1$   
Padding:  $p = 0$

$$\boxed{6} = 9*1 + 2*0 + 5*(-1) + 6*1 + 2*0 + 4^*(-1) + 4*1 + 5*0 + 4^*(-1)$$

## EXEMPLOS DE CONVOLUÇÃO

-1	-1	-1	-1	-1	-1	-1	-1	-1
-1	1	-1	-1	-1	-1	-1	1	-1
-1	-1	1	-1	-1	-1	1	-1	-1
-1	-1	-1	1	-1	1	-1	-1	-1
-1	-1	-1	-1	1	-1	-1	-1	-1
-1	-1	-1	1	-1	1	-1	-1	-1
-1	-1	-1	1	-1	1	-1	-1	-1
-1	1	-1	-1	-1	-1	1	-1	-1
-1	-1	-1	-1	-1	-1	-1	-1	-1

1	-1	-1
-1	1	-1
-1	-1	1

0.77	-0.11	0.11	0.33	0.55	-0.11	0.33
-0.11	1.00	-0.11	0.33	-0.11	0.11	-0.11
0.11	-0.11	1.00	-0.33	0.11	-0.11	0.55
0.33	0.33	-0.33	0.55	-0.33	0.33	0.33
0.55	-0.11	0.11	-0.33	1.00	-0.11	0.11
-0.11	0.11	-0.11	0.33	-0.11	1.00	-0.11
0.33	-0.11	0.55	0.33	0.11	-0.11	0.77

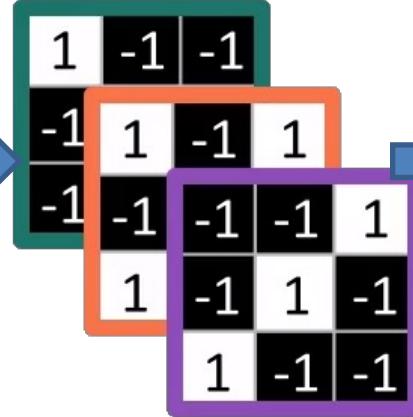
Matriz de Entrada  
(imagem)

Kernel

Mapa de Ativação

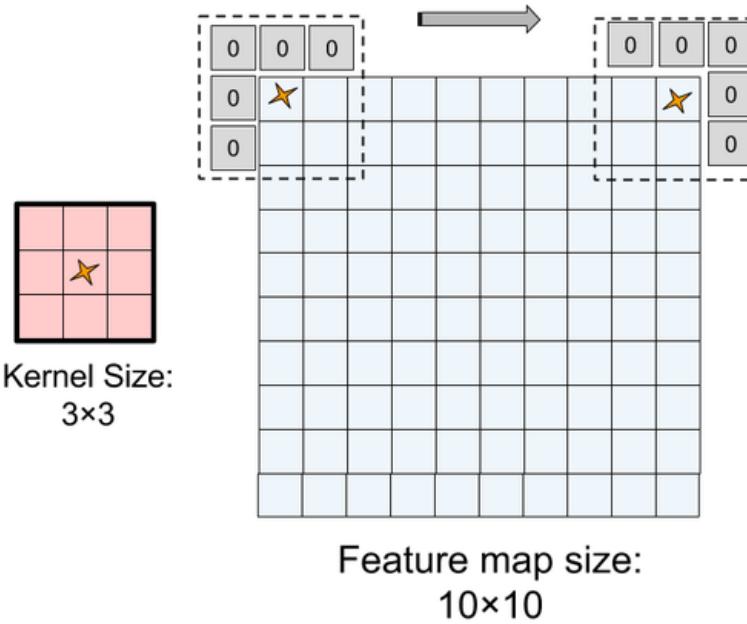
## EXEMPLOS DE CONVOLUÇÃO

-1	-1	-1	-1	-1	-1	-1	-1	-1
-1	1	-1	-1	-1	-1	-1	1	-1
-1	-1	1	-1	-1	-1	1	-1	-1
-1	-1	-1	1	-1	1	-1	-1	-1
-1	-1	-1	-1	1	-1	-1	-1	-1
-1	-1	-1	-1	-1	1	-1	-1	-1
-1	-1	-1	1	-1	1	-1	-1	-1
-1	-1	1	-1	-1	-1	1	-1	-1
-1	1	-1	-1	-1	-1	-1	1	-1
-1	-1	-1	-1	-1	-1	-1	-1	-1



0.77	-0.11	0.11	0.33	0.55	-0.11	0.33		
-0.11	0.33	-0.55	0.11	-0.11	0.11	-0.55	0.33	
0.11	-0.55	0.33	-0.11	0.11	-0.11	0.33	-0.11	0.11
0.33	0.11	0.55	-0.11	0.11	-0.11	0.33	-0.11	1.00
0.55	-0.11	0.55	-0.11	0.11	-0.33	1.00	-0.11	0.11
-0.11	0.33	0.33	0.33	-0.33	0.55	-0.33	0.33	0.33
0.33	-0.55	0.11	-0.11	1.00	-0.33	0.11	-0.11	0.55
0.33	-0.11	1.00	-0.11	0.33	-0.11	0.11	-0.11	-0.11
0.77	-0.11	0.11	0.33	0.55	-0.11	0.33		

# REDES NEURAIS CONVOLUCIONAIS PADDING



# REDES NEURAIS CONVOLUCIONAIS PADDING

0	0	0	0	0	0	0	0
0	60	113	56	139	85	0	0
0	73	121	54	84	128	0	0
0	131	99	70	129	127	0	0
0	80	57	115	69	134	0	0
0	104	126	123	95	130	0	0
0	0	0	0	0	0	0	0

Kernel

0	-1	0
-1	5	-1
0	-1	0

114				

# REDES NEURAIS CONVOLUCIONAIS

## STRIDE

<i>Input</i>						
4	9	2	5	8	3	
2	4	5	4	0	3	
5	6	5	4	7	8	
5	7	7	9	2	1	
5	8	5	3	8	4	

Dimension:  $6 \times 6$

*Filter*

1	0	-1
1	0	-1
1	0	-1

\*

*Result*

2	1

=

Parameters:

Size:  $f = 3$

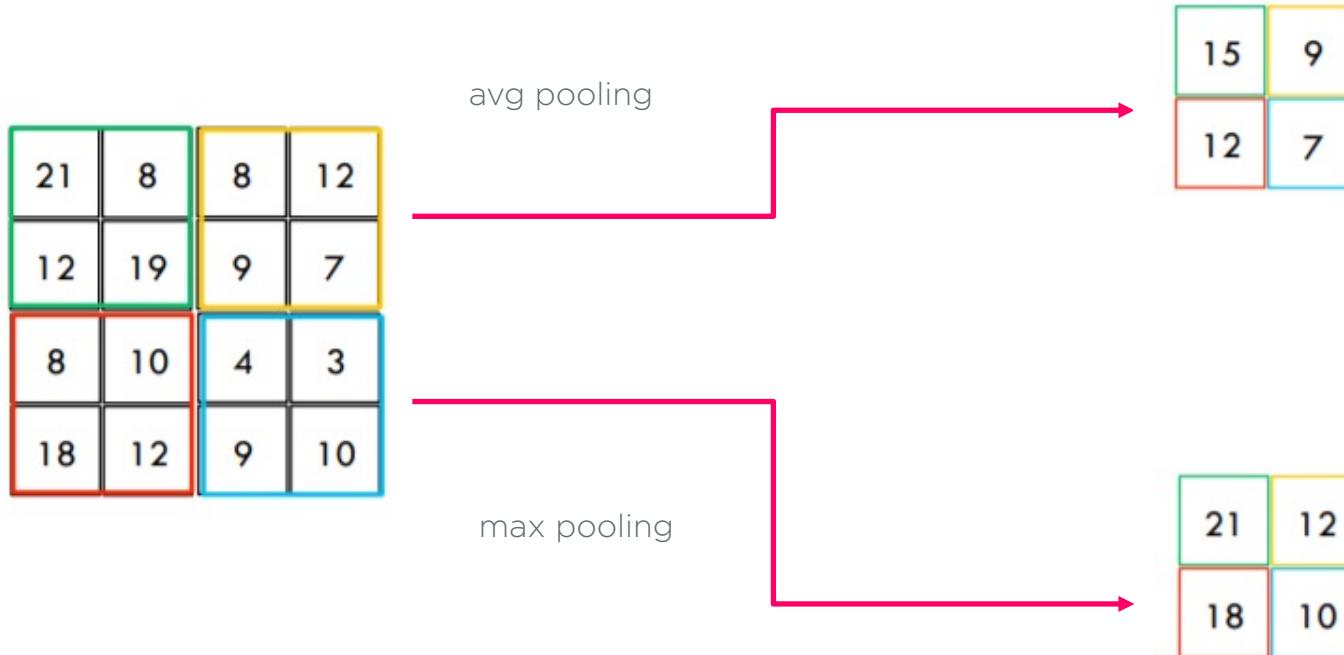
Stride:  $s = 2$

Padding:  $p = 0$

$$1 = 2*1 + 5*0 + 3*(-1) + \\ 2*1 + 4*0 + 3*(-1) + \\ 5*1 + 4*0 + 2*(-1)$$

<https://indoml.com>

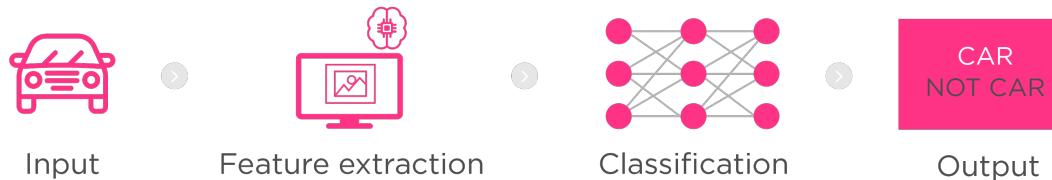
# REDES NEURAIS CONVOLUCIONAIS SUBAMOSTRAGEM



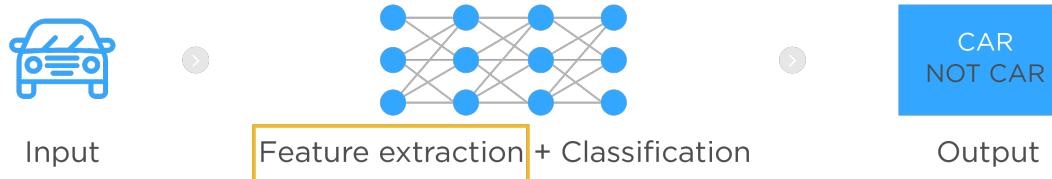
# REDES NEURAIS CONVOLUCIONAIS

O que estamos fazendo com convolução e subamostragem?

## Machine Learning

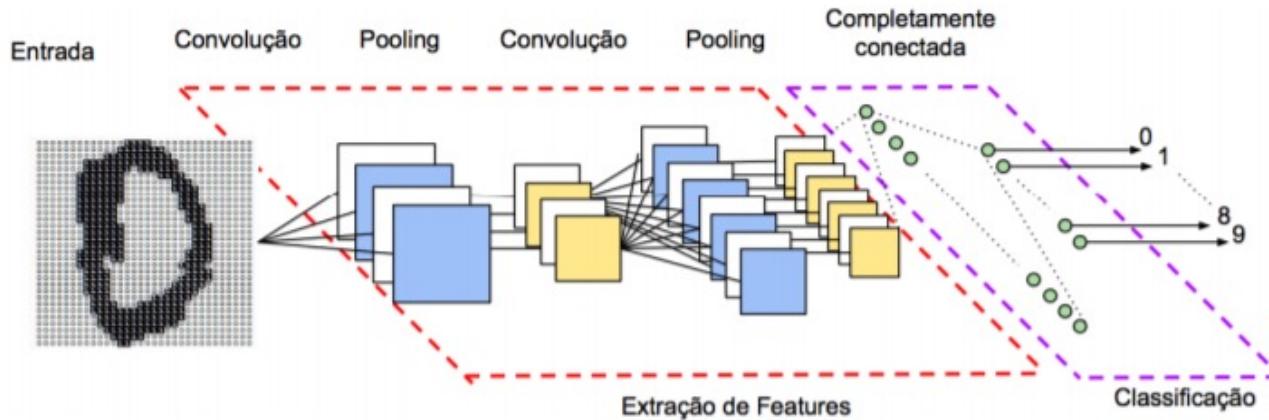


## Deep Learning



# REDES NEURAIS CONVOLUCIONAIS

## ARQUITETURA GERAL



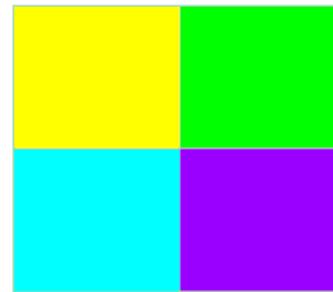
Fonte: MEDEIROS NETO, F. G.; PINTO JÚNIOR, R. F.; ROCHA, M. G. O. et al. Aprendizado profundo: conceitos, técnicas e estudo de caso de análise de imagens com Java. III Escola Regional de Informática do Piauí. *Livro Anais - Artigos e Minicursos*, v. 1, n. 1, pp. 465-486, jun. 2017.

# REDES NEURAIS CONVOLUCIONAIS

## ARQUITETURA GERAL

- Mas como as CNNs calibram os Kernels (filtros) durante o treinamento?

$X_{11}$	$X_{12}$	$X_{13}$
$X_{21}$	$X_{22}$	$X_{23}$
$X_{31}$	$X_{32}$	$X_{33}$



$\partial h_{11}$	$\partial h_{12}$
$\partial h_{21}$	$\partial h_{22}$

$$\partial W_{11} = X_{11}\partial h_{11} + X_{12}\partial h_{12} + X_{21}\partial h_{21} + X_{22}\partial h_{22}$$

$$\partial W_{12} = X_{12}\partial h_{11} + X_{13}\partial h_{12} + X_{22}\partial h_{21} + X_{23}\partial h_{22}$$

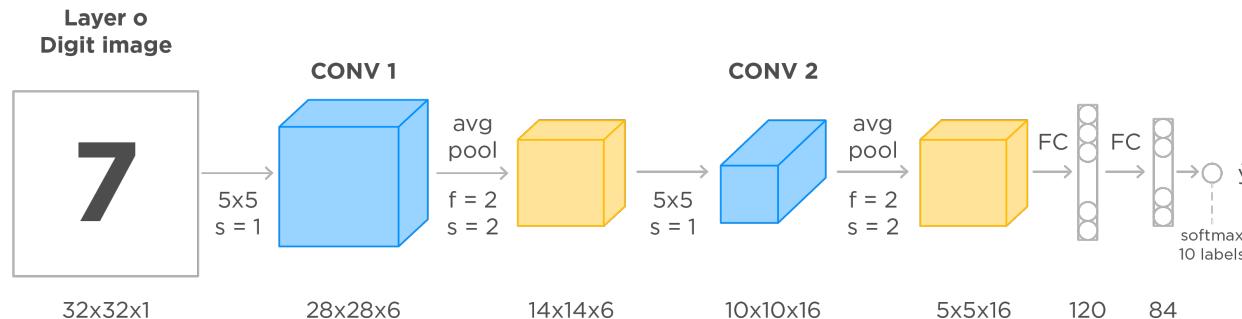
$$\partial W_{21} = X_{21}\partial h_{11} + X_{22}\partial h_{12} + X_{31}\partial h_{21} + X_{32}\partial h_{22}$$

$$\partial W_{22} = X_{22}\partial h_{11} + X_{23}\partial h_{12} + X_{32}\partial h_{21} + X_{33}\partial h_{22}$$

# REDES NEURAIS CONVOLUCIONAIS ARQUITETURAS CONHECIDAS

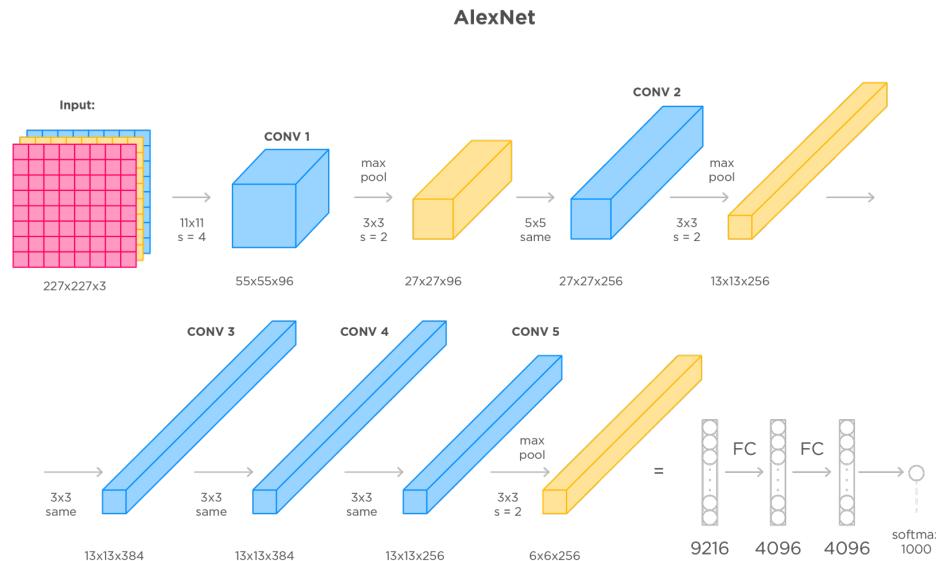
- Número de parâmetros: 60 mil

**LeNet - 5**



# REDES NEURAIS CONVOLUCIONAIS ARQUITETURAS CONHECIDAS

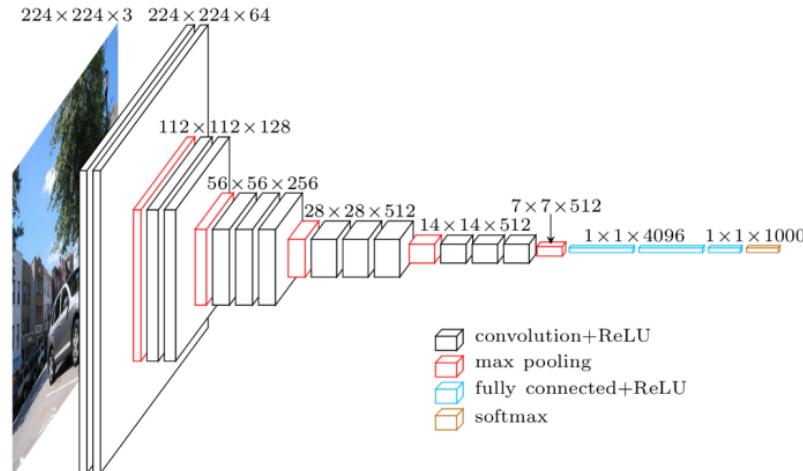
- Número de parâmetros: 60 milhões



Alex Krizhevsky, Geoffrey Hinton, and Ilya Sutskever Improving neural networks by preventing co-adaptation of feature detectors. arXiv preprint arXiv:1207.0580, 2012.

# REDES NEURAIS CONVOLUCIONAIS ARQUITETURAS CONHECIDAS

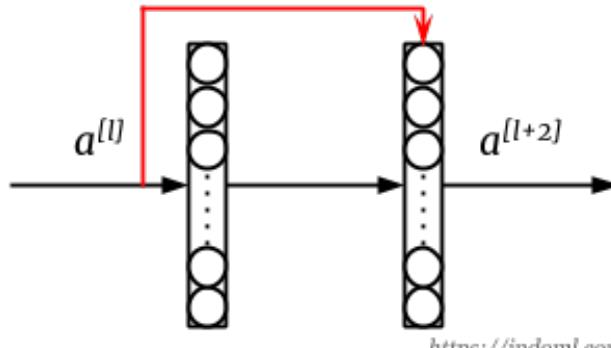
- Número de parâmetros: 138 milhões
- VGG-16 from Very Deep Convolutional Networks for Large-Scale Image Recognition



## REDES NEURAIS CONVOLUCIONAIS ARQUITETURAS CONHECIDAS

- Número de parâmetros: 25 milhões (ResNet50)

ResNet - Deep Residual Learning for Image Recognition

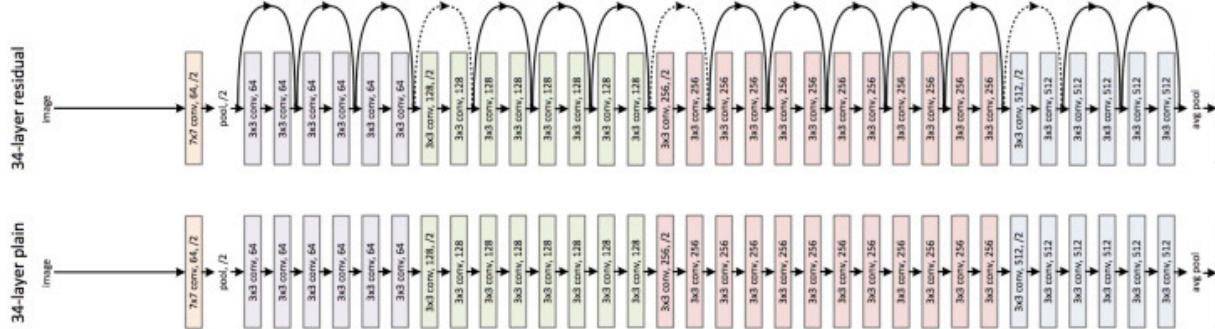


$$z^{[l+2]} = W^{[l+2]} a^{[l+1]} + b^{[l+2]}$$

$$a^{[l+2]} = g^{[l+2]}(z^{[l+2]} + a^{[l]})$$

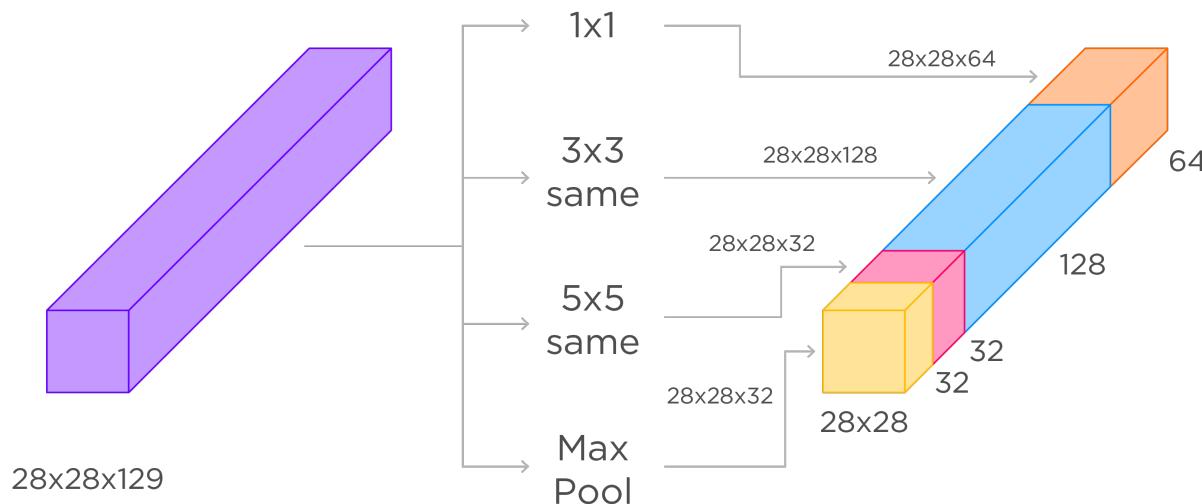
# REDES NEURAIS CONVOLUCIONAIS ARQUITETURAS CONHECIDAS

## ResNet - Deep Residual Learning for Image Recognition



# REDES NEURAIS CONVOLUCIONAIS ARQUITETURAS CONHECIDAS

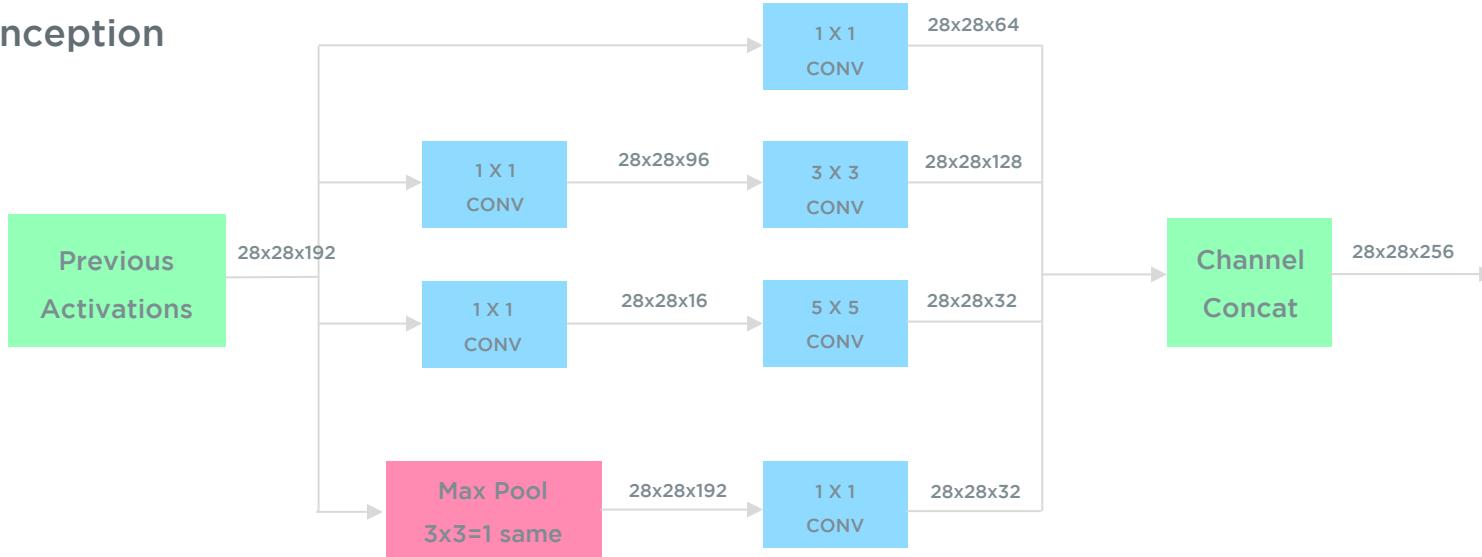
## Inception



# REDES NEURAIS CONVOLUCIONAIS

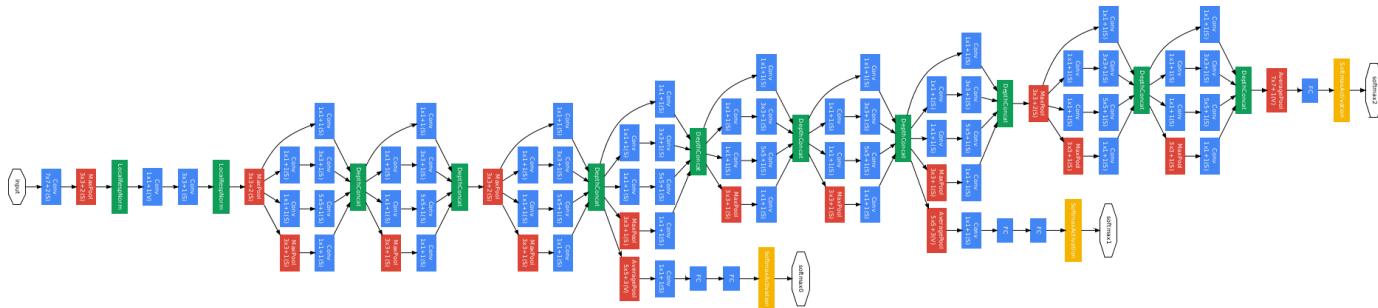
## ARQUITETURAS CONHECIDAS

Inception



# REDES NEURAIS CONVOLUCIONAIS ARQUITETURAS CONHECIDAS

## Inception - Google LeNet



# REDES NEURAIS CONVOLUCIONAIS

- É possível realizar a convolução 1D?



## REDES NEURAIS CONVOLUCIONAIS

- Em que cenários é interessante utilizar Conv 1D?
- Para que tipos de problemas?

## DISCUSSÃO

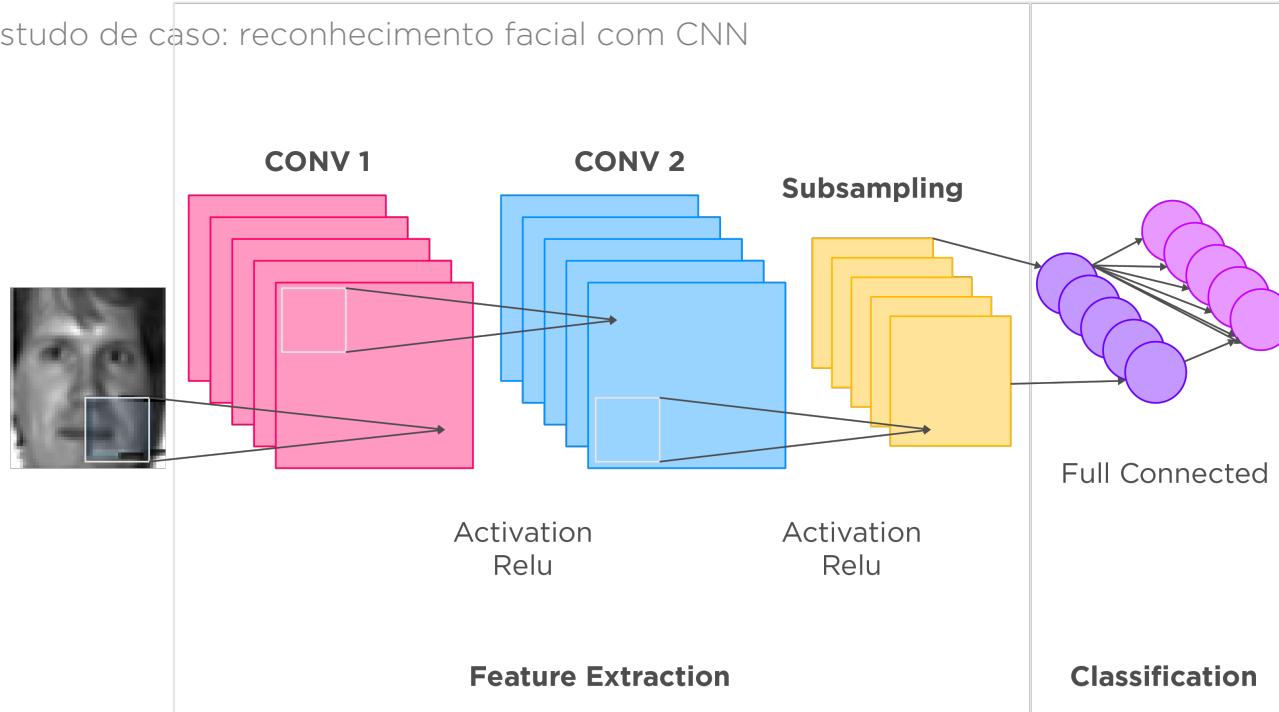
## REDES NEURAIS CONVOLUCIONAIS

- Quando utilizar CNN?
- Por onde começar a resolver o problema com cnn?

## DISCUSSÃO

# REDES NEURAIS CONVOLUCIONAIS

- Estudo de caso: reconhecimento facial com CNN



# REDES NEURAIS CONVOLUCIONAIS

- Estudo de caso: reconhecimento facial com CNN

## CNN-based FR

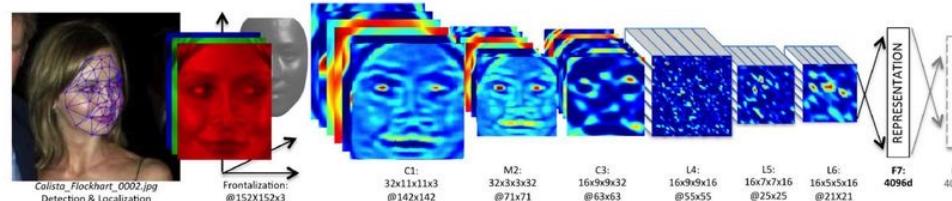
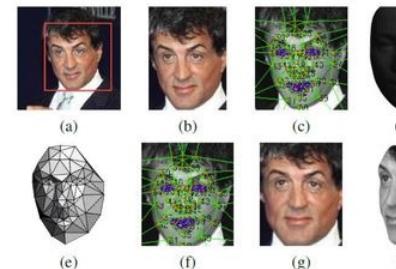
### DeepFace

Alignment: 2D, 3D

Input: RGB image 152x152

Output feature size: 4096

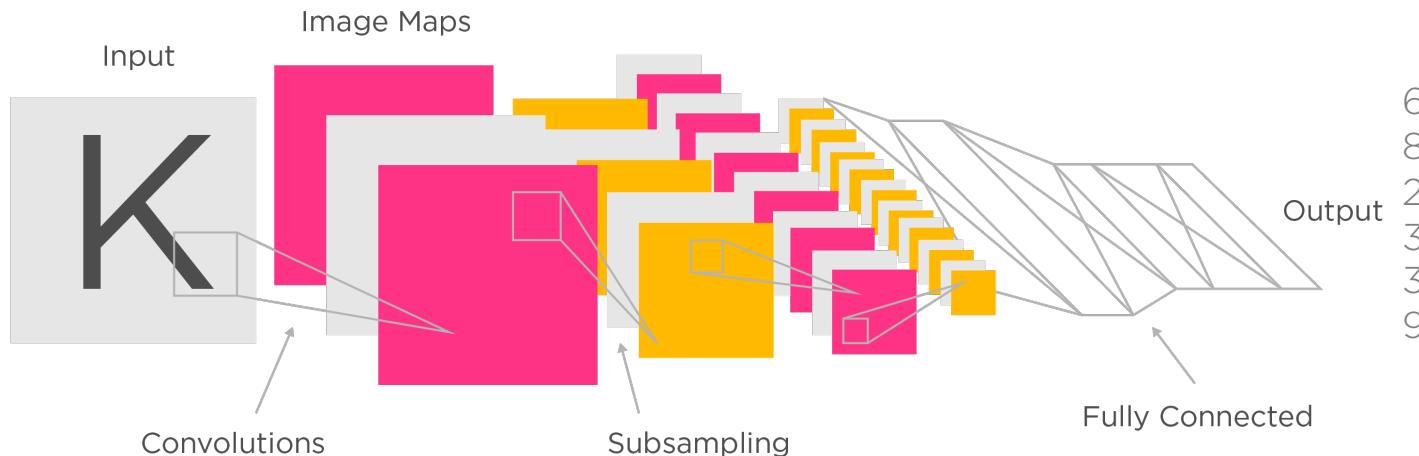
Parameters: ~ 120 million



Y. Taigman, M. Yang, M. Ranzato, and L. Wolf. Deepface: Closing the gap to human-level performance in face verification. In CVPR, 2014

# REDES NEURAIS CONVOLUCIONAIS

- Estudo de caso: problema OCR Notas Fiscais
- Deep Learning de alta capacidade para classificar caracteres com ruído e defeitos de impressão.



• • • • .  
• • • . . .  
• + . REDES NEURAIS  
+ • CONVOLUCIONAIS

HANDS ON #4:  
**CLASSIFICAÇÃO DE IMAGENS COM  
KERAS + TENSORFLOW E DATASET  
MNIST**

• • • • . . .  
• • • . . . . .  
• + . . REDES NEURAIS  
+ . CONVOLUCIONAIS

HANDS ON #5:  
**CLASSIFICAÇÃO DE IMAGENS  
COLORIDAS COM KERAS +  
TENSORFLOW E DATASET CIFAR10**

# OBRIGADO

FIAP

Copyright © 2020 | Professor Felipe Gustavo Silva Teodoro

Todos os direitos reservados. A reprodução ou divulgação total ou parcial deste documento é expressamente proibida sem o consentimento formal, por escrito, do(a) professor(a)/autor(a).

+

• • • • • .  
• • • • • .  
• + .  
+ •

|

+

FIAP

• +  
■ □ •  
• • •  
• •

• •