


# Classificação: KNN





## ML: Classificação - KNN (vizinhos próximos)


a) A labeled dataset has three distict groups



- Class 1
- Class 2



#### ML: Classificação - KNN (vizinhos próximos)





# KNN: Train Test Split

•

from sklearn.model\_selection import train\_test\_split
X\_train, X\_test, y\_train, y\_test = train\_test\_split(df
X\_train.head(3)

	months_last_claim	<pre>engine_size</pre>	is_male	age	
11.	6	200	0	44	18
	12	70	0	58	14
	6	70	1	44	36

•

•



#### KNN: is sensitive to features scale

+

```
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
data_scaled = scaler.fit_transform(df)
df_scaled = pd.DataFrame(data_scaled, columns = df.columns)
df_scaled
```

	age	is_male	engine_size	months_last_claim	fraud
0	0.743243	0.0	0.384615	1.000000	1.0
1	0.324324	0.0	0.000000	0.333333	1.0
2	0.837838	0.0	1.000000	0.333333	0.0

\_

. . •



```
KNN: fit, score, predict
```

```
from sklearn.neighbors import KNeighborsClassifier
knn = KNeighborsClassifier(n_neighbors=3)
knn.fit(X_train,y_train)
train_accuracy= knn.score(X_train,y_train)*100
print(train_accuracy)
knn.predict(X_test)
```

```
82.5 array([0, 0, 0, 0, 0, 0, 1, 1, 1, 0, 0, 0, 1, 0, 0, 0, 1, 1, 1, 0])
```

+ + •



### KNN: "hyperparameter tuning"

```
for k in range(3,20,1):
  knn = KNeighborsClassifier(n_neighbors=k)
  knn.fit(X_train,y_train)
  train_accuracy= knn.score(X_train,y_train)*100
  print(k,train_accuracy)
3 82.5
4 72.5
5 70.0
6 72.5
7 65.0
8 62.5
9 65.0
10 66.25
11 65.0
12 62.5
13 66.25
14 62.5
15 65.0
16 62.5
17 65.0
18 60.0
19 60.0
```




#### KNN: "hyperparameter tuning"

preds = knn.predict(X test)

from sklearn.metrics import confusion\_matrix
print(accuracy\_score(y\_test,preds)\*100)
print(confusion\_matrix(y\_test,preds))
print(classification report(y test,preds))

	precision	recall	f1-score	support
0 1	0.50 0.50	0.50 0.50	0.50 0.50	10 10
accuracy			0.50	20
macro avg	0.50	0.50	0.50	20
weighted avg	0.50	0.50	0.50	20





Exercício: kNN

- · · · + · □
- Utilizando o algoritmo do kNN, treine seu modelo para reconhecer os clientes com bom perfil de crédito e os que n\u00e3o.
  - Aplique seu modelo treinado ao um conjunto novo de potenciais clientes.
  - Avalie o nível de qualidade do seu modelo, calculando as seguintes métricas
    - Accuracy
    - Precision
    - Recall

**treino**: https://raw.githubusercontent.com/lcbjrrr/data/main/RiscoCredito%20-%20okk.csv **teste**: https://raw.githubusercontent.com/lcbjrrr/data/main/RiscoCredito%20-%20prever2.csv



# **MATH MEN**

Analytics · Resultados · Lógica

Google






- Escolha uma base de dados no <a href="https://www.kaggle.com/datasets">https://www.kaggle.com/datasets</a>, e se familiarize com sua base
- Procure realizar a previsão (inferência) de uma variável categórica através de um kNN. Se certifique de medir seus níveis de assertividade. Esteja a vontade a realizar mais um hiperparâmetro (número de vizinhos) de um e compará-los
- Não esqueça de junto com seus códigos realizar suas análises/conclusões (use o botão de +Texto).

. .

· · • •



#### Separação Treino Teste





#### Matriz de Confusão

		Predicted		
		0	1	
Actual	0	TN	FP	
	1	FN	TP	

$$Precision = \frac{TP}{TP + FP}$$
 
$$Recall = \frac{TP}{TP + FN}$$

#### **Actual**

**Predicted** 

True **False** Precision: TPTrue False TP + FPPositive Positive (TP)(FP) Negative **Predictive Value:** False True False TNNegative Negative TN + FN(FN)(TN)

Sensitivity: Specificity: Accuracy:

$$\frac{TP}{TP + FN} \qquad \frac{TN}{TN + FP} \qquad \frac{TP + TN}{TP + TN + FP + FN}$$